

Threads/warp (NT)

	K	Threads/warp (NT)			
		4	8	16	32
TF32	128	3.96	3.71	6.11	4.38
	256	3.85	3.70	6.27	4.78
	512	3.77	3.64	6.23	4.96
	1024	3.80	3.55	6.44	5.22
BF16	128	7.72	7.29	11.29	6.96
	256	7.61	7.17	12.15	8.53
	512	7.58	7.30	12.57	9.56
	1024	7.68	7.47	13.93	11.01
FP8	128	12.60	11.55	16.98	9.53
	256	14.20	13.51	21.23	13.49
	512	14.99	14.17	23.44	17.08
	1024	15.57	14.95	27.46	21.25

(a) Speedup over scalar FP32

Threads/warp (NT)

	K	Threads/warp (NT)			
		4	8	16	32
IW = 2	128	1.47	1.30	1.37	1.21
	256	1.47	1.31	1.39	1.22
	512	1.48	1.30	1.41	1.23
	1024	1.48	1.29	1.41	1.24
IW = 4	128	1.83	1.47	1.66	1.25
	256	1.84	1.48	1.67	1.31
	512	1.82	1.48	1.70	1.35
	1024	1.84	1.47	1.68	1.36
IW = 8	128	2.01	1.48	1.70	1.18
	256	2.01	1.52	1.77	1.26
	512	2.01	1.51	1.79	1.32
	1024	2.02	1.51	1.81	1.35

(b) BF16 WGMMA over IW = 1