

Threads per warp (sparse layout)

		4 (sym.)	8 (asym.)	16 (sym.)	32 (asym.)
TF32	K				
	128	0.71	1.45	1.14	1.37
	256	0.82	1.37	1.45	1.59
	512	1.10	1.53	1.32	1.75
BF16	1024	1.05	1.78	1.12	1.61
	128	0.72	1.32	0.91	1.31
	256	0.71	1.46	1.04	1.45
	512	0.81	1.51	1.28	1.54
FP8	1024	1.06	1.66	1.16	1.68
	128	0.80	1.25	1.01	1.24
	256	0.80	1.40	1.06	1.33
	512	0.78	1.47	1.16	1.45
	1024	0.83	1.63	1.27	1.63